

Introducao a Big Data e Data Analytics

Projeto Final 1 - Etapa 1

Dataset e descritivo do problema

Avistamentos UFO: padrões temporais, geográficos e contextuais

Aluno: Erick Bonruque

RA: 2587246

Base principal	UFO Sightings - Kaggle, derivada do NUFORC
Granularidade da fato	Cada linha representa um relato individual de avistamento
Dimensão obrigatória	Quando: data, ano, mês, dia da semana, hora e data de postagem
Recorte inicial	Análise histórica global, com atenção especial para vieses dos EUA
Tipo de problema	Análise exploratória, cruzamento de fontes e identificação de padrões

1. Dataset escolhido

O dataset escolhido é o UFO Sightings do Kaggle (via kagglehub), baseado em registros do NUFORC (organização que cataloga avistamentos incomuns). A base tem formato tabular simples, ideal para análise, contendo: data do avistamento, local (cidade, estado, país, latitude e longitude), formato, duração, comentário e data de postagem.

Link database principal: <https://www.kaggle.com/datasets/sahityasetu/ufo-sightings>

O dataset atende ao requisito de possuir mais de 10.000 registros e dados históricos de vários anos. Além disso, ele permite construir uma tabela de fato central de avistamentos e várias dimensões analíticas, incluindo a dimensão temporal obrigatória. Como os dados possuem campos geográficos, categorias, temporais e textuais, a base também permite trabalhar com análises descritivas, séries temporais, mapas, agrupamentos e enriquecimento com fontes externas.

1.1 Campos principais previstos

Campo	Descricao	Uso analitico
datetime	Data e horário do avistamento	Base para a dimensão Quando
city, state, country	Local informado no relato	Base para dimensão geográfica
shape	Formato percebido pelo observador	Categoria do tipo de relato
duration	Duração estimada do evento	Medida quantitativa da fato
comments	Descrição textual do relato	Análise textual e classificação
date posted	Data em que o relato foi publicado	Permite calcular atraso de reporte
latitude, longitude	Coordenadas geográficas	Mapas e cruzamento com outras bases

2. Problema a ser resolvido

- **Problema central.** Identificar padrões temporais, geográficos e contextuais associados ao aumento de relatos de UFOs e verificar a influência de fatores conhecidos (clima, aeroportos, lançamentos espaciais, satélites, picos culturais) nesses avistamentos.
- **Pergunta orientadora.** Quando e onde os relatos de UFO aparecem com maior intensidade, e quais fatores externos ajudam a explicar esses picos de ocorrência?
- **Motivação.** O tema é ideal para a disciplina por possuir grande volume e variedade de dados (temporal, espacial, categórico, textual) e permitir enriquecimento com outras fontes. A análise possibilita discutir vieses de observação, comportamento social, eventos aeroespaciais e qualidade dos dados, além de ser divertido.

2.1 Perguntas analíticas iniciais

- Em quais anos, meses, horários e dias da semana há maior número de relatos?
- Quais países, estados e cidades concentram mais avistamentos?

- Quais formatos relatados, como light, circle, triangle ou fireball, aparecem com maior frequência?
- A duração dos eventos possui padrões ou muitos outliers?
- Existe atraso relevante entre a data do avistamento e a data de postagem?
- Eventos climáticos, aeroportos ou lançamentos espaciais ajudam a explicar parte dos picos?

3. Proposta inicial de Data Warehouse

A modelagem proposta segue um esquema estrela simples. A tabela fato representa os avistamentos, enquanto as dimensões descrevem tempo, local, formato, fonte dos dados e variáveis externas usadas para enriquecer a análise. Essa estrutura facilita consultas agregadas, dashboards e comparações entre períodos, regiões e categorias.

Tabela	Papel	Exemplos de atributos/medidas
fato_avistamento	Registro individual do relato	duracao_segundos, lag_reporte_dias, latitude, longitude, quantidade_relato
dim_tempo	Quando ocorreu e quando foi postado	ano, mes, dia, hora, dia_semana, trimestre
dim_local	Onde ocorreu	cidade, estado, pais, latitude, longitude, regioao
dim_formato	Como o objeto foi descrito	shape_original, shape_normalizado, grupo_formato
dim_fonte	Origem do registro	Kaggle/NUFORC, GEIPAN, Hugging Face, GEP
dim_clima	Contexto meteorologico	cobertura_nuvens, visibilidade, vento, temperatura, codigo_clima
dim_aeroporto	Proximidade de aeroportos	aeroporto_mais_proximo, distancia_km, tipo_aeroporto

dim_evento_espacial	Lançamentos e eventos espaciais próximos	missão, agencia, data lancamento, distancia_janela
dim_interesse_cultural	Indicadores de interesse público	pageviews_mensais, termo, idioma, plataforma

4. Expansões escolhidas para enriquecer a base

As expansões abaixo foram escolhidas porque são públicas, possuem formatos simples, exigem poucas transformações e se conectam naturalmente aos campos já existentes no dataset principal, principalmente data, hora, latitude, longitude, pais e comentário textual.

Expansao	Formato	Chave de integracao	Contribuicao	Dificuldade
Open-Meteo Historical Weather	API historica de clima	lat/lon + data/hora	Adicionar cobertura de nuvens, visibilidade, vento e temperatura para testar se o clima influencia os relatos.	Facil
OurAirports	CSV público de aeroportos	distancia geográfica por lat/lon	Calcular o aeroporto mais próximo e verificar se relatos se concentram perto do tráfego aéreo.	Facil
Launch Library 2	API de lançamentos espaciais	janela temporal + distância do local de lançamento	Checar se picos de relatos aparecem perto de lançamentos, reentradas ou eventos especiais.	Facial-media
Wikimedia Pageviews	API de visualización de páginas	ano/mes + termo UFO/UAP/OV NI	Medir interesse cultural e midiático para avaliar possível aumento de repórteres em períodos de maior atenção pública.	Facil

GEIPAN - Franca	CSV/lista publica oficial	schema similar to NUFORC	Adicionar casos oficiais franceses e campos de classificação, aumentando a cobertura internacional e qualidade da fonte.	Facil
Hugging Face Ufo_data_clustered	JSONL consolidado	campos ja normalizados	Usar como fonte complementar com mais registros padronizados é possível redução de trabalho de limpeza.	Trivial

4.1 Justificativa das expansões

- **Clima:** Variáveis meteorológicas podem ajudar a filtrar relatos explicáveis por fenômenos atmosféricos (luzes, nuvens, reflexos, baixa visibilidade).
- **Aeroportos:** Proximidade de aeroportos e rotas aéreas pode indicar que relatos estão ligados a tráfego comercial, luzes de pouso, drones ou aeronaves.
- **Lançamentos espaciais:** Eventos como foguetes e satélites geram relatos em massa por pessoas sem contexto técnico. Integração por tempo e distância é direta.
- **Viés cultural:** Alto interesse midiático em UFO/UAP pode aumentar a propensão de observação, interpretação e relato de eventos celestes.

Bases complementares: GEIPAN e Hugging Face permitem ampliar cobertura e comparar fontes, mantendo a rastreabilidade (source_id e source case_id).

5. Estratégia de tratamento e integração

1. Padronizar nomes de colunas, tipos de dados, datas, coordenadas e duração em segundos.
2. Criar campos temporais derivados: ano, mês, dia da semana, hora, trimestre e lag de reporte.
3. Normalizar categorias de shape, preservando o valor original para auditoria.
4. Criar um identificador de fonte e caso original para permitir rastreabilidade.

5. Integrar bases externas usando chaves simples: data/hora, latitude/longitude, país, cidade ou janela temporal.
6. Gerar tabelas dimensionais e a tabela fato para permitir consultas por período, local, categoria e contexto.

6. Escopo inicial e limites

Para viabilizar a entrega, não serão priorizadas fontes que exijam OCR complexo, PDFs históricos ou raspagem juridicamente sensível. Bases como Project Blue Book, Arquivo Nacional do Brasil, CIA/CEFAE Argentina e MUFON foram levantadas, mas não serão utilizadas agora por exigirem maior trabalho de extração e revisão manual. Não será feito scraping direto do site do NUFORC; usaremos apenas a cópia pública já disponível em repositórios como Kaggle.

7. Referências e fontes previstas

- Kaggle - UFO Sightings: <https://www.kaggle.com/datasets/sahityasetu/ufo-sightings>
- NUFORC - National UFO Reporting Center: <https://nuforc.org/>
- Open-Meteo Historical Weather API:
<https://open-meteo.com/en/docs/historical-weather-api>
- OurAirports - data downloads: <https://ourairports.com/data/>
- The Space Devs - Launch Library 2 API: <https://ll.thespacedevs.com/2.2.0/>
- Wikimedia Analytics API - Pageviews:
<https://doc.wikimedia.org/generated-data-platform/aqs/analytics-api/reference/page-views.html>
- GEIPAN/CNES - recherche de cas: <https://www.cnes-geipan.fr/en/recherche/cas>
- Hugging Face - cjc0013/Ufo_data_clustered:
https://huggingface.co/datasets/cjc0013/Ufo_data_clustered